Deusto
Facultad de Ingeniería
Faculty of Engineering

Fundamentos del Procesamiento de Lenguaje Natural
E2 – Procesamiento y análisis de los datos.

1. Resumen de la entrega

Nota	10%
Fecha	28 de octubre de 2026 a las 23:55

2. Instrucciones

El propósito principal de esta entrega es empezar con el procesamiento de todos los corpus que se van a usar durante el transcurso del proyecto (tanto anotados como no anotados) para su posterior representación en cualquiera de las diversas formas de representación de palabras que hemos visto durante el curso.

Esta entrega debería contener los siguientes apartados:

- Código y documentación de cómo se ha tokenizado, dividido en oraciones o cualquier otro proceso que se haya llevado a cabo.
- Código y documentación de cómo el texto ya procesado se ha representado con Bag of Words o TF-IDF. (Si se considera que no se va a usar en ningún momento este apartado puede ser ignorado pero tiene que estar justificado).
- Código y documentación de cómo el texto ya procesado se ha representado con Word embeddings.
    - Análisis de cuántas palabras no se pueden representar con la técnica de Word embeddings que se haya utilizado.
    - En el caso de que el número de palabras sin poder ser representadas sea grande, analizar la posibilidad de entrenar vuestro propio Word2Vec.
- Código y documentación de cómo todo el texto queda estructurado en un JSON/CSV/otro formato que ayude en su reutilización.